

SAE — Prédiction d'une Variable Quantitative

Premiers pas dans le Machine Learning

Régression Linéaire Multiple — Données Cancer
BUT Science des Données — 2025-2026

Orian GIRAUD et Théo GARDERE

I. Introduction — Le Machine Learning

1.1 Définition et concepts fondamentaux

Le Machine Learning (ML) est la discipline qui donne aux ordinateurs la capacité d'apprendre à partir des données, sans être explicitement programmés pour chaque tâche. Contrairement à l'algorithmique classique où les règles sont codées en dur, les algorithmes de ML construisent eux-mêmes une fonction de décision à partir des exemples qu'ils observent.

Trois ingrédients sont indispensables à toute démarche ML :

- Les données : base d'apprentissage. Leur qualité conditionne entièrement celle du modèle (« Garbage in, Garbage out »).
- Le modèle : structure mathématique paramétrée. Ici, une régression linéaire multiple.
- L'algorithme d'optimisation : mécanisme qui ajuste les paramètres du modèle (les β) pour minimiser l'erreur de prédiction.

On distingue trois grandes familles de ML :

- Apprentissage supervisé : on dispose de couples (x_i, y_i) — entrée + sortie connue. L'algorithme apprend à prédire y à partir de x . C'est notre cas.
- Apprentissage non supervisé : on ne dispose que des entrées x_i , sans étiquette. L'objectif est de découvrir des structures cachées (clustering, réduction de dimension).
- Apprentissage par renforcement : un agent apprend par essais-erreurs en recevant des récompenses ou pénalités selon ses actions.

1.2 Apprentissage supervisé et régression linéaire

Nous nous plaçons dans le cadre de l'apprentissage supervisé pour une variable quantitative continue : c'est un problème de régression. L'objectif est de construire un modèle qui prédit le diamètre d'une tumeur cancéreuse (variable Y) à partir de dix tests médicaux quantitatifs (X_1 à X_{10}).

Le modèle de régression linéaire multiple s'écrit :

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_{10} x_{i10}$$

où les coefficients β sont estimés par la méthode des moindres carrés ordinaires (MCO), qui minimise la somme des carrés des résidus : $\sum (y_i - \hat{y}_i)^2$.

1.3 Démarche générale suivie

La démarche adoptée dans cette SAE suit rigoureusement les étapes du cours :

- Importation et vérification des données (valeurs manquantes)
- Imputation des valeurs manquantes par la médiane (SimpleImputer)
- Exploration statistique et graphique (boxplots, histogrammes KDE)
- Détection des valeurs extrêmes par deux méthodes (quartiles et z-score) et choix argumenté
- Trois études comparatives selon la stratégie de traitement des extrêmes
- Pour chaque étude : split 80/20, centrage-réduction, régression, R^2 , R^2 ajusté, s^2 , K-Fold CV
- Synthèse comparative et sélection du meilleur modèle

II. Description des données et préparation

2.1 Importation

Le fichier cancer_sae2026.csv contient 20 000 observations et 12 colonnes : un identifiant numérique (supprimé car non informatif), dix variables explicatives quantitatives X1 à X10 représentant des tests médicaux, et la variable cible Y correspondant au diamètre de la tumeur. Les valeurs manquantes sont codées par le caractère point « . ».

Valeurs manquantes détectées : 11 au total — X1 (3 valeurs), X3 (4 valeurs), X7 (4 valeurs). Toutes imputées par la **médiane** de chaque variable via SimpleImputer. Ce choix est justifié par la robustesse de la médiane face aux valeurs extrêmes : contrairement à la moyenne, elle n'est pas influencée par des observations aberrantes.

2.2 Exploration statistique

Les statistiques descriptives révèlent une forte hétérogénéité entre les variables : les ordres de grandeur vont de valeurs proches de zéro ($X1 \approx 0,27$ en moyenne, $X3 \approx 0,31$) à des milliers ($X9 \approx 1\,053$, $X4 \approx 251$). Cette disparité rend le centrage-réduction indispensable avant toute modélisation, afin que chaque variable contribue équitablement.

2.3 Visualisation — Boîtes à moustaches et distributions




Figure 1 — Boîtes à moustaches des 10 variables explicatives (données brutes après imputation)

La Figure 1 révèle des valeurs très isolées sur X1, X4, X6, X9 et X10 qui écrasent l'échelle et confirment la nécessité d'un traitement. Les variables X2, X3, X7, X8 apparaissent plus homogènes.




Figure 2 — Distributions des 10 variables explicatives (histogrammes + densités KDE)

L'analyse des histogrammes complète la lecture des boxplots. X2, X7 présentent des distributions quasi-uniformes. X3, X5, X8 sont proches d'une loi normale symétrique. En revanche, X1, X6, X9, X10 sont fortement concentrées sur une plage étroite avec quelques valeurs très isolées — typique de mesures biologiques à distribution asymétrique.

III. Détection des valeurs extrêmes — Choix de la méthode

3.1 Comparaison des deux méthodes

Deux méthodes ont été testées sur les 10 variables pour détecter les valeurs extrêmes :

- Méthode des quartiles (IQR) : valeur extrême si $< Q1 - 1,5 \times IQR$ ou $> Q3 + 1,5 \times IQR$. Robuste mais parfois trop sensible sur des variables à fort étalement.
- Méthode du z-score : valeur extrême si $|z| = |(x_i - \bar{x}) / \sigma| > 3$. Repose sur la règle des $\pm 3\sigma$ (99,7% des observations sous hypothèse de normalité).

Le tableau ci-dessous compare les deux méthodes variable par variable :

Variable	Nb quartiles	% quartiles	Nb z-score	% z-score
X1	25	0.125	3	0.015
X2	0	0.000	0	0.000
X3	0	0.000	0	0.000
X4	5	0.025	5	0.025
X5	5	0.025	5	0.025
X6	8	0.040	8	0.040
X7	0	0.000	0	0.000
X8	0	0.000	0	0.000
X9	2	0.010	2	0.010
X10	11	0.055	8	0.040

→ **Méthode quartiles** : 19 944 observations conservées sur 20 000 (perte de 0,3%). La variable X1 génère à elle seule 25 valeurs extrêmes avec la méthode IQR contre seulement 3 avec le z-score. Cette méthode s'avère trop agressive sur ce jeu de données.

→ **Méthode z-score** : 19 969 observations conservées sur 20 000 (perte de 0,2% seulement). C'est la méthode retenue pour l'Étude 1.

3.2 Trois stratégies comparées

Conformément à la démarche du cours, trois stratégies sont testées sur les mêmes données :

- Étude 1 — Suppression par z-score ($|z| > 3$) : suppression des 31 observations aberrantes.
- Étude 2 — Écrêtement par winsorisation à 1% : les valeurs au-delà du 99e percentile sont ramenées à ce seuil, sans suppression d'observation.
- Étude 3 — Données brutes : aucun traitement des extrêmes, servant de référence.

IV. Modélisation et évaluation

4.1 Pipeline commun aux 3 études

Pour chacune des trois études, la même pipeline rigoureuse est appliquée :

- Séparation en ensemble d'apprentissage (80%, ~16 000 obs.) et de test (20%, ~4 000 obs.) via `train_test_split` avec `random_state=42` pour la reproductibilité.
- Centrage-réduction des X : `StandardScaler` ajusté (`fit_transform`) sur le train uniquement, puis appliqué (`transform`) au test — principe fondamental pour éviter toute fuite d'information du test vers le train.
- Centrage-réduction de Y : même principe, moyenne et écart-type calculés sur `ytrain` uniquement.
- Ajustement de la régression linéaire multiple (`LinearRegression`, Scikit-Learn).
- Évaluation par R^2 , R^2 ajusté et s^2 sur les deux ensembles.
- Validation croisée K-Fold avec $k=5$ plis sur l'ensemble d'apprentissage.

R^2 ajusté : indicateur qui pénalise l'ajout de variables non informatives. Il est défini par $R^2_{aj} = 1 - (1 - R^2) \times (n-1)/(n-p-1)$ avec $p=10$ prédicteurs. Si $R^2_{aj} \approx R^2$, cela confirme que les 10 variables sont toutes utiles au modèle.

4.2 Étude 1 — Sans les valeurs extrêmes (z-score)



Figure 3 — Boîtes à moustaches après suppression des valeurs extrêmes (Étude 1, 19 969 obs.)

Après suppression des 31 observations aberrantes (0,2% des données), les distributions sont nettement plus propres. La modélisation donne :




Figure 4 — Prédications vs valeurs réelles — Étude 1 (R^2 Train = 0,9069 ; R^2 Test = 0,9029)

Les points s'alignent très bien sur la diagonale rouge (droite parfaite $\hat{y} = y$), aussi bien en apprentissage qu'en test. Le modèle explique ~90% de la variance du diamètre de la tumeur.

R^2 train = 0,9069 — R^2 ajusté train = 0,9068 : R^2 ajusté quasi-identique confirme que les 10 variables sont toutes pertinentes.

R^2 test = 0,9029 — R^2 ajusté test = 0,9027 : très proche du R^2 train → aucun surapprentissage.

Validation croisée (5 plis) : 0,9048 | 0,9067 | 0,9057 | 0,9067 | 0,9098 → moyenne = 0,9067, écart-type = 0,0017. Les 5 plis donnent des scores quasi-identiques : le modèle est très stable et reproductible.

4.3 Analyse des coefficients β

L'examen des coefficients β (sur données centrées-réduites) permet d'identifier les variables les plus influentes sur le diamètre de la tumeur :

Variable	Coefficient β
X9	0.5879
X8	0.2841
X5	0.2518
X6	-0.1807
X3	0.1057
X4	0.0452
X2	0.0380
X10	0.0322
X7	0.0132
X1	0.0057




Figure 5 — Coefficients β de la régression linéaire (Étude 1, variables centrées-réduites)

X9 ($\beta = 0,588$) et X8 ($\beta = 0,284$) sont de loin les variables les plus influentes. X5 contribue également positivement ($\beta = 0,252$). À l'inverse, **X6 a un effet négatif ($\beta = -0,181$)** : une augmentation de X6 est associée à une diminution du diamètre prédit. X1 et X7 ont des coefficients très faibles, leur contribution est marginale. Tous les β sont non nuls, ce qui justifie a posteriori la conservation des 10 variables (confirmé par R^2 ajusté $\approx R^2$).

4.4 Étude 2 — Écrêtement par winsorisation 1%




Figure 6 — Boîtes à moustaches après écrêtement par winsorisation 1% (Étude 2, 20 000 obs.)

La winsorisation conserve l'intégralité des 20 000 observations en remplaçant les valeurs au-delà du 99e percentile par ce seuil. Les distributions sont comparables à celles de l'Étude 1.




Figure 7 — Prédictions vs valeurs réelles — Étude 2 (R^2 Train = 0,9068 ; R^2 Test = 0,9039)

Les résultats sont très proches de l'Étude 1 : R^2 train = 0,9068, R^2 test = 0,9039. La CV donne $0,9066 \pm 0,0024$. Légèrement moins stable que l'Étude 1 (écart-type 0,0024 contre 0,0017) mais reste excellent.

4.5 Étude 3 — Données brutes (aucun traitement)




Figure 8 — Prédictions vs valeurs réelles — Étude 3 (R^2 Train = 0,9055 ; R^2 Test = 0,9027)

En surface, les indicateurs R^2 semblent satisfaisants. Mais la validation croisée révèle une instabilité catastrophique :

- Pli 1 : -753,27 ← ABERRANT
- Pli 2 : 0,9016

- Pli 3 : 0,9068
- Pli 4 : 0,9072
- Pli 5 : 0,9049

→ **Moyenne = -149,93 / Écart-type = 301,67**. Le premier pli de validation contenait dans son ensemble de test une valeur extrême suffisante pour provoquer un effondrement total du modèle. Ce résultat illustre parfaitement pourquoi la validation croisée est indispensable : les indicateurs train/test « classiques » masquaient totalement ce problème.

V. Synthèse comparative

Le tableau ci-dessous récapitule tous les indicateurs calculés pour les trois études, incluant le R^2 ajusté et les scores détaillés de validation croisée :

Étude	R^2 Train	R^2_{aj} Tr	R^2 Test	R^2_{aj} Te	s^2 Test	CV Moy.	CV Std
Étude 1 — Sans extrêmes	0.9069	0.9068	0.9029	0.9027	0.0943	0.9067	0.0017
Étude 2 — Écrêtement 1%	0.9068	0.9067	0.9039	0.9036	0.0942	0.9066	0.0024
Étude 3 — Brutes	0.9055	0.9055	0.9027	0.9025	0.0953	-149.93	301.67

Scores de validation croisée détaillés par pli :

Étude	Pli 1	Pli 2	Pli 3	Pli 4	Pli 5
Étude 1 — Sans extrêmes	0.9048	0.9067	0.9057	0.9067	0.9098
Étude 2 — Écrêtement 1%	0.9063	0.9031	0.9096	0.9089	0.9053
Étude 3 — Brutes	-753.27	0.9016	0.9068	0.9072	0.9049




Figure 9 — Comparaison des indicateurs R^2 des 3 études (R^2 Train, Test et CV Moyen)

La barre « R^2 CV Moyen » est absente pour l'Étude 3 car la valeur est fortement négative (-149,93) et ne peut pas être représentée sur cette échelle — ce qui illustre visuellement à quel point ce modèle est inutilisable en production.

VI. Conclusion — Modèle retenu et enseignements

6.1 Modèle retenu : Étude 1

Nous retenons l'Étude 1 — suppression des valeurs extrêmes par z-score — comme modèle final. Les arguments sont les suivants :

- R^2 train (0,9069) $\approx$ R^2 test (0,9029) : pas de surapprentissage, le modèle généralise bien à des données inconnues.
- R^2 ajusté $\approx$ R^2 (écart $< 0,0002$) : les 10 variables explicatives sont toutes utiles, aucune ne dilue le modèle.
- Validation croisée la plus stable : CV std = 0,0017, soit la moitié de celle de l'Étude 2. Les 5 plis oscillent entre 0,9048 et 0,9098 — résultats très reproductibles.
- Perte de données négligeable : seulement 31 observations supprimées sur 20 000 (0,2%).
- Variable X9 est le prédicteur dominant ($\beta = 0,588$), suivi de X8 (0,284) et X5 (0,252). X6 a un effet négatif ($-0,181$).

6.2 Pourquoi rejeter l'Étude 3 malgré un bon R^2 apparent ?

L'Étude 3 illustre un piège classique en ML : un bon score sur l'ensemble de test ne garantit pas la robustesse du modèle. Une seule valeur extrême dans le premier pli de la validation croisée a suffi à provoquer un R^2 de -753 , révélant une instabilité totale. En conditions réelles, ce modèle pourrait produire des prédictions complètement aberrantes sur de nouvelles données contenant des valeurs atypiques.

6.3 Enseignements méthodologiques

Cette SAE illustre trois principes fondamentaux du ML :

- La qualité de la préparation des données conditionne directement la qualité du modèle final. L'exploration préalable (boxplots, histogrammes) est indispensable.
- Le centrage-réduction doit être appris sur le train uniquement (fit sur train, transform sur test) pour éviter toute contamination par les données de test.
- La validation croisée K-Fold est un outil de diagnostic essentiel : elle peut révéler une fragilité cachée qu'un simple split train/test ne détecterait pas.

Comme le souligne le cours, chaque jeu de données a ses propres particularités — la stratégie gagnante ici (suppression par z-score) n'est pas universelle et doit toujours être justifiée par une analyse empirique comparative, telle que celle menée dans cette SAE.

Modèle final : Régression Linéaire Multiple — Étude 1 (z-score) $R^2(\text{test}) = 0,9029$ $R^2_{\text{aj}} = 0,9027$ CV = $0,9067 \pm 0,0017$
